

Exploración de soluciones neuro-simbólicas al benchmark ARC-AGI usando modelos de lenguaje ligeros y representación simbólica eficiente

1INF46 Proyecto de Fin de Carrera 2

Saymon Nicho

PUCP

26 de agosto de 2025

1. Generalidades

Resolución neuro-simbólica del benchmark ARC-AGI usando modelos de lenguaje ligeros y representación simbólica eficiente

Asesor: César Beltrán, PhD

Co-asesor: Edwin Villanueva, PhD

Explorar las arquitecturas con **enfoque neuro-simbólico** que sirvan para resolver de forma eficiente problemas que involucren razonamiento y abstracción, tomando como referencia el *benchmark* **ARC-AGI** para su evaluación.

Propuesto por **Francois Chollet** en 2019 como un benchmark para evaluar *human-like intelligence* en modelos de IA ^[1].




Figura 1: Benchmark ARC-AGI




Figura 2: Árbol de Problemas

La problemática principal es la **difícultad actual que presentan los modelos de IA** para demostrar capacidades de **razonamiento y abstracción**, así como **generalización** efectiva a partir de pocos ejemplos.

En benchmarks como ARC-AGI se evidencia cómo las arquitecturas actuales, principalmente LLMs, tienen **limitaciones significativas en términos de eficiencia**, además de sufrir dependencia de grandes volúmenes de datos para su entrenamiento y operación.




Figura 3: Relación entre Problemas y Objetivos

O1. Diseñar arquitecturas híbridas que integren redes neuronales ligeras y módulos de razonamiento simbólico para abordar el benchmark ARC-AGI.	
Resultado Esperado	Medio de Verificación
R1. Selección de técnicas y algoritmos con enfoque neuro-simbólico.	- Informe de selección de técnicas con análisis comparativo . Debe ser aprobado por un experto en IA.
R2. Selección de <i>datasets</i> incluyendo el original de ARC-AGI.	- Repositorio en Google Drive con al menos 3 datasets adicionales al original.
R3. <i>Pipelines</i> base donde se integren los módulos seleccionados.	- Código fuente en Python de los <i>pipelines</i> base implementados, junto a un informe técnico .

Cuadro 1: Resultados Esperados y Medios de Verificación para el Objetivo 1

O2. Implementar una biblioteca de transformaciones genéricas y reutilizables para la resolución de los distintos tipos de problemas propuestos en ARC-AGI, de forma que estas se integren como módulo de razonamiento simbólico en la arquitectura.	
Resultado Esperado	Medio de Verificación
R1. Biblioteca en Python con transformaciones elementales que permitan la resolución de problemas de ARC-AGI.	- Código fuente en Python de la biblioteca donde se implementen al menos 10 operaciones atómicas .
R2. Validación de la biblioteca mediante su evaluación en subtarear preseleccionadas de ARC-AGI.	- <i>Notebook</i> para evaluación automatizada sobre un subconjunto de subtarear de los datasets elegidos.
R3. Documentación que detalle el uso de la biblioteca, las funciones que incluye y ejemplos de uso.	- <i>Notebooks</i> que demuestren el uso de la biblioteca con ejemplos.

Cuadro 2: Resultados Esperados y Medios de Verificación para el Objetivo 2

O3. Entrenar las arquitecturas asegurando un costo computacional bajo mediante técnicas de fine-tuning y test-time training de manera que la solución sea eficiente en términos de recursos y tiempo de ejecución.	
Resultado Esperado	Medio de Verificación
R1. Aplicación de <i>fine-tuning</i> para ajuste de capas y parámetros.	- Registro de hiperparámetros y pesos finales con al menos 2 métricas comparativas entre el modelo base y el modelo ajustado.
R2. Evaluación cuantitativa de recursos usados (consumo de GPU/CPU, memoria y tiempos de inferencia).	- Reporte con análisis comparativo entre los recursos usados por el modelo base y el ajustado. - Informe que detalle el proceso de evaluación y los resultados obtenidos. Debe ser aprobado por un experto en IA.

Cuadro 3: Resultados Esperados y Medios de Verificación para el Objetivo 3

O4. Evaluar las arquitecturas en el benchmark ARC-AGI y compararlas con el estado del arte, publicando los resultados en un repositorio público.	
Resultado Esperado	Medio de Verificación
R1. Evaluación de la arquitectura en los <i>datasets</i> público y semi-privado del benchmark.	- Código en Python para la evaluación del modelo final.
R2. Comparación de resultados con los de arquitecturas del estado del arte.	- Reporte con análisis comparativo entre los resultados obtenidos y los del estado del arte.
R3. Discusión final sobre limitaciones encontradas y oportunidades de mejora.	- Informe de conclusiones donde se discuta la efectividad de las técnicas utilizadas.
R4. Publicación del proyecto en un repositorio abierto.	- Repositorio público en GitHub con licencia MIT, código fuente, reportes e informes.

Cuadro 4: Resultados Esperados y Medios de Verificación para el Objetivo 4



Figura 4: Métodos, Herramientas y Técnicas

2. Plan de Proyecto

La tesis sustenta su relevancia en los siguientes puntos:

- **Contribución conceptual:** se refuerza el marco conceptual sobre *human-like general intelligence* y razonamiento en sistemas de IA [1].
- **Aporte metodológico:** se adopta una metodología exploratoria y experimental, para lo cual permite analizar empíricamente y comparar el desempeño de diferentes enfoques.
- **Pertinencia en el estado del arte:** se aborda un área de creciente interés y de rápida evolución, como es la integración de enfoques neuro-simbólicos aplicada al *benchmark* ARC-AGI.

Técnica: Bibliografía, recursos académicos, computación accesible, herramientas, experiencia

Económica: Recursos tecnológicos cubiertos por el Grupo de Investigación IA PUCP

Temporal: Cronograma realista con duración estimada de 10 meses

El objetivo es **estrictamente académico** y busca contribuir a la generación de conocimiento científico.

Alcance:

Centrado en IA eficiente con arquitecturas neuro-simbólicas para el benchmark ARC-AGI.

Actividades principales:

- Revisión y selección de técnicas del estado del arte
- Diseño e implementación de *pipelines* neuro-simbólicos
- Optimización de los *pipelines* (LoRA, *test-time adaptation*)
- Evaluación comparativa de los resultados

Limitaciones:

- **Tiempo:** Plazo de 10 meses limita análisis profundo y experimentos.
- **Complejidad técnica:** Integración de modelos de lenguaje con módulos simbólicos puede resultar desafiante.

- **Personas involucradas y necesidades de capacitación**

- Saymon Estefano Nicho Manrique
- Dr. César Beltrán
- Dr. Edwin Villanueva
- Especialista en inteligencia artificial

- **Equipamiento requerido**

- Computadora personal
- Servidores del Grupo de Investigación IA PUCP

- **Herramientas requeridas**

- Python
- PyTorch
- Jupyter Notebooks
- Visual Studio Code
- Zotero
- Google Drive
- GitHub




Figura 5: Cronograma de tareas del proyecto

3. Resultado Esperado

Resultado Esperado

Se seleccionaron 3 conjuntos de datos adicionales al original para el desarrollo, entrenamiento y evaluación de las arquitecturas neuro-simbólicas.

- **ARC-AGI** original (<https://github.com/fchollet/ARC-AGI>).
- **ConceptARC** (<https://github.com/victorvikram/ConceptARC>).
- **Re-ARC** (<https://github.com/michaelhodel/re-arc>).
- **ARC-Heavy** (<https://github.com/xu3kev/BARC>).




Figura 6: *Datasets* en Google Drive

- [1]. François Chollet.
On the measure of intelligence.
arXiv preprint arXiv:1911.01547, 2019.