

PONTIFICIA UNIVERSIDAD CATÓLICA DEL PERÚ

Facultad de Ciencias e Ingeniería



*Resolución neuro-simbólica del benchmark
ARC-AGI utilizando modelos de lenguaje ligeros y
representación simbólica eficiente*

Proyecto de Fin de Carrera 2 (1INF46)

Entregable 3

Saymon Estefano Nicho Manrique

Asesores:

Dr. César Beltrán

Dr. Edwin Villanueva

28 de noviembre de 2025

Índice

1. Generalidades	6
1.1. Problemática	6
1.1.1. Árbol de Problemas	6
1.1.2. Descripción	7
1.1.3. Problema Seleccionado	8
1.2. Objetivos	8
1.2.1. Objetivo General	9
1.2.2. Objetivos Específicos	9
1.2.3. Resultados Esperados	9
1.2.4. Mapeo de Resultados Esperados y Medios de Verificación	10
1.3. Metodología	13
1.3.1. Herramientas para la Revisión del Estado del Arte	15
1.3.2. Herramientas para el Desarrollo e Implementación de la Solución	15
1.3.3. Herramientas para el Almacenamiento y Gestión de Versiones	15
1.3.4. Métodos Empleados	15
1.3.5. Procedimientos Empleados	16
2. Marco Referencial	17
2.1. Marco Teórico	17
2.1.1. Inteligencia General	17
2.1.2. Razonamiento en sistemas de IA	18
2.1.3. Enfoque Neuro-Simbólico	18
2.2. Marco Conceptual	19
2.2.1. Benchmark	19
2.2.2. ARC-AGI	19
2.2.3. Generalización	19
2.2.4. Eficiencia	20
2.2.5. Modelo de Lenguaje Ligero	20
3. Estado del Arte	21
3.1. Introducción	21
3.2. Objetivos de la Revisión	21
3.3. Preguntas de Revisión	21
3.4. Protocolo de Búsqueda	22
3.4.1. Motores de Búsqueda	22
3.4.2. Cadenas de Búsqueda	22
3.4.3. Criterios de Inclusión y Exclusión	23
3.4.4. Documentos Seleccionados	24
3.5. Formulario de Extracción	26
3.6. Resultados de la Revisión	26
3.6.1. Respuesta a la Pregunta 1	26
3.6.2. Respuesta a la Pregunta 2	27
3.6.3. Respuesta a la Pregunta 3	27
3.6.4. Respuesta a la Pregunta 4	28
3.6.5. Respuesta a la Pregunta 5	28
4. Diseño de la Arquitectura Neuro-Simbólica	30

4.1.	Técnicas y Algoritmos Seleccionados	30
4.1.1.	Deep Learning-Guided Program Synthesis	30
4.1.2.	Test-Time Fine-Tuning	30
4.1.3.	Data Augmentation	31
4.1.4.	Ensamble de Modelos (Inductivo y Transductivo)	31
4.2.	Datasets seleccionados	31
4.2.1.	ARC-AGI (original)	31
4.2.2.	ConceptARC	32
4.2.3.	Re-ARC	32
4.2.4.	ARC-Heavy	32
4.3.	Pipeline Base	33
4.4.	Discusión de Resultados	35
5.	Módulo Simbólico de la Arquitectura	36
5.1.	Diseño e Implementación de la Biblioteca	36
5.2.	Validación y Evaluación	37
5.3.	Documentación y Uso	37
5.4.	Discusión de Resultados	37
6.	Entrenamiento del Pipeline	38
6.1.	Entrenamiento del Módulo Transductivo	38
6.1.1.	Preprocesamiento del Dataset	39
6.1.2.	Modelos Base y Cuantización en 4 Bits	39
6.1.3.	Reducción del Espacio de Tokens	40
6.1.4.	Formateo de las Tareas para el Fine-Tuning	40
6.1.5.	Fine-tuning Supervisado con LoRA y Unsloth	40
6.1.6.	Ajuste en Tiempo de Inferencia	41
6.2.	Entrenamiento del Módulo Inductivo	42
6.2.1.	Modelo Base y Esquema de Entrenamiento	42
6.3.	Esquema de Ensamble y Mecanismo de Fallback	43
6.4.	Discusión de Resultados	44
7.	Evaluación de la Arquitectura Propuesta	45
7.1.	Protocolo de Evaluación	45
7.2.	Evaluación del Módulo Transductivo	45
7.3.	Evaluación del Módulo Inductivo	46
7.4.	Evaluación del Ensamble	46
7.5.	Comparación de Recursos Computacionales	47
7.6.	Discusión de Resultados	48
8.	Conclusiones y Trabajos Futuros	50
8.1.	Conclusiones	50
8.2.	Trabajos Futuros	51
	Referencias	52
A.	Formulario de Extracción	56

Índice de Tablas

1.	Resultados esperados, medios de verificación e IOV para el O1	10
2.	Resultados esperados, medios de verificación e IOV para el O2	11
3.	Resultados esperados, medios de verificación e IOV para el O3	11
4.	Resultados esperados, medios de verificación e IOV para el O4	12
5.	Herramientas, métodos y procedimientos para los resultados del O1	13
6.	Herramientas, métodos y procedimientos para los resultados del O2	13
7.	Herramientas, métodos y procedimientos para los resultados del O3	14
8.	Herramientas, métodos y procedimientos para los resultados del O4	14
9.	Cadenas y resultados en diferentes motores de búsqueda.	23
10.	Cantidad de documentos seleccionados por motor de búsqueda.	24
11.	Documentos seleccionados para la revisión sistemática.	25
12.	Formulario de extracción de datos para la revisión sistemática.	26
13.	Hiperparámetros usados en el entrenamiento con UnslotTrainer	41
14.	Hiperparámetros usados en el entrenamiento del módulo inductivo	43
15.	Resultados de evaluación del módulo transductivo (pass@2)	46
16.	Resultados de evaluación del módulo inductivo (pass@2)	46
17.	Resultados de evaluación del ensamble (pass@2)	47
18.	Desempeño del ensamble propuesto frente al SOTA (pass@2).	47
19.	Recursos computacionales utilizados en el proyecto	48
20.	Comparación de recursos entre el proyecto y el SOTA	48
21.	Riesgo por falta de recursos computacionales adecuados.	65
22.	Riesgo de fallo en computador personal.	65
23.	Riesgo de dificultades técnicas.	65
24.	Riesgo de desaparición de herramientas o bibliotecas.	65
25.	Lista de tareas	67
26.	Costeo del proyecto	69

Índice de Figuras

1.	Árbol de problemas	7
2.	Esquema de entrenamiento	34
3.	Esquema de inferencia	34
4.	Representación visual de la tarea 0520fde7.	59
5.	Representación visual de la tarea 29c11459.	60
6.	Representación visual de la tarea 25ff71a9.	61

Índice de Apéndices

A.	Formulario de Extracción	56
B.	Datasets Seleccionados	57
C.	Repositorio del Proyecto	58
D.	Estructura de Tareas de ARC	59
E.	Plan de Proyecto	62

1. Generalidades

1.1. Problemática

Desde su concepción en la década de 1950, el campo de la inteligencia artificial (IA) ha perseguido el desarrollo de sistemas capaces no solo de realizar tareas específicas, sino también de aprender y razonar de manera generalizada, emulando la versatilidad de la inteligencia humana. Esta aspiración, comúnmente denominada *artificial general intelligence* (AGI), debería demostrar capacidades de razonamiento y comprensión de abstracciones que puedan extrapolarse a distintas áreas de conocimiento.

A pesar de los avances recientes en modelos basados en redes neuronales, especialmente en tareas de reconocimiento de patrones como la visión por computadora o el procesamiento de lenguaje natural, estos aún presentan limitaciones como la necesidad de extensos volúmenes de datos para su entrenamiento, y la dificultad para resolver problemas que involucran razonamiento y generalización a partir de pocos ejemplos.

Esta brecha entre la capacidad actual de los modelos puramente neuronales y la generalización requerida por una inteligencia más versátil ha motivado la exploración de enfoques alternativos. Una dirección prometedora es el paradigma neuro-simbólico, ya que combina el poder de las redes neuronales con la estructura y lógica de los sistemas simbólicos, buscando emular procesos cognitivos humanos.

En este contexto, el *benchmark* Abstraction and Reasoning Corpus for Artificial General Intelligence (ARC-AGI) se ha posicionado como un referente clave para evaluar dichas capacidades, al proponer problemas que exigen comprensión abstracta y extrapolación a partir de pocos ejemplos (Chollet, 2019). Este *benchmark* se destaca actualmente pues incluso modelos de gran escala en el estado del arte como O3 y O4-Mini (OpenAI, 2025) no han logrado resolverlo en su totalidad, lo cual ha subrayado la necesidad de investigar soluciones más efectivas y eficientes (Chollet, Knoop, Kamradt, Landers & Pinkard, 2025).

Ante este escenario, la presente investigación propone el desarrollo de una alternativa neuro-simbólica basada en modelos neuronales ligeros y técnicas de representación simbólica eficientes, con el objetivo de abordar el *benchmark* ARC-AGI.

Como punto de partida, se utiliza la técnica de árbol de problemas para sistematizar la problemática y abordar sus causas y efectos principales.

1.1.1. Árbol de Problemas

El árbol de problemas es una herramienta analítica y visual que permite identificar y estructurar una situación problemática en un proyecto, estudio o investigación (Vesely, 2008). Su implementación representa gráficamente la problemática principal en el centro, las causas que la originan en la parte inferior y los efectos que se derivan de ella en la parte superior. Esta disposición simula una estructura de árbol, donde la raíz representa las causas, el tronco el problema central y las ramas los efectos.

En la figura 1 se presenta el árbol de problemas del proyecto, donde la problemática se centra en la falta de soluciones neuro-simbólicas eficientes para el *benchmark* ARC-AGI.




Figura 1: Árbol de problemas

1.1.2. Descripción

La inteligencia, desde una perspectiva moderna, se define como la eficiencia en la adquisición de nuevas habilidades y conocimientos. Según esta definición propuesta por Chollet (2019), un sistema con inteligencia general (*general intelligence*) debería ser capaz de aprender a partir de pocos ejemplos y de operar eficientemente con recursos limitados. Así, uno de los principales obstáculos para el desarrollo de modelos que se aproximen a esta definición es la dificultad para emular computacionalmente cualidades propias del proceso de aprendizaje en los seres humanos, como el razonamiento, la abstracción y la generalización extrema. Aunque recientemente modelos grandes basados en redes neuronales, como los *Large Language Models* (LLMs), han demostrado capacidades emergentes en razonamiento al utilizar técnicas como el *prompting* o la generación de cadenas de pensamiento (COT), estas habilidades han resultado muy superficiales y no se han podido extrapolar a distintos tipos de problemas ajenos a los que originalmente fueron planteados a resolver (Huang & Chang, 2022).

Este problema se ha visto agravado por la dependencia extrema de estos modelos en grandes volúmenes de datos de acuerdo a estudios recientes. Según Boopathy y Fiete (2024), actualmente la capacidad de los modelos requiere proporcionalmente un aumento en la cantidad de datos y tiempo de entrenamiento; lo cual implica que, aunque los modelos muy grandes pueden demostrar habilidades avanzadas en tareas complejas, lo hacen con una eficiencia computacional y energética extremadamente baja. Además, se ha observado de forma empírica que habilidades que requieren razonamiento avanzado, como

la generación de código o la respuesta de preguntas complejas basadas en conocimientos de matemáticas o ciencias, son las que más dependen de la cantidad y variedad de datos disponibles al momento de su entrenamiento (Roberts et al., 2025).

Por ello, el *benchmark* ARC-AGI se ha convertido en un referente clave, evidenciando la necesidad de explorar nuevos enfoques en el campo de *deep learning* y el razonamiento en sistema de IA. Dado que en los últimos años la mayoría de los esfuerzos se han centrado en el desarrollo de modelos masivos que requieren grandes volúmenes de datos y recursos computacionales, muy reducida parte de la comunidad científica le ha dado la importancia o atención necesaria a la búsqueda de soluciones eficientes y reproducibles a este *benchmark*. Para motivar esta búsqueda, el equipo de ARC-AGI lanzó en 2024 una competencia en Kaggle (ARC Prize Foundation, 2024), y ha sido en esta donde se han presentado los primeros resultados prometedores. Sin embargo, según el *ARC Prize Technical Report 2024* (Chollet, Knoop, Kamradt & Landers, 2025), incluso el ganador logró apenas una precisión del 55.5 %, lejos del objetivo establecido de alcanzar un 85 %. Esto demostró la necesidad de seguir explorando enfoques alternativos en el campo.

Para resolver las limitaciones mencionadas anteriormente, la mayoría de las soluciones presentadas optó por arquitecturas neuro-simbólicas. La fortaleza de este enfoque híbrido radica en su capacidad para superar las limitaciones individuales que los paradigmas simbólico y neuronal presentan por separado (Sinha et al., 2024). Por ello, lo que se busca en la actualidad es una integración efectiva y estandarizada. Así, el enfoque neuro-simbólico, aunque prometedor, aún debe superar retos de integración y eficiencia antes de poder ser considerado una solución viable y definitiva para *benchmarks* similares a ARC-AGI (Nadin, 2023).

Es importante recalcar que, este *benchmark* busca evaluar solo algunos de los múltiples aspectos involucrados en el proceso de aprendizaje humano, por lo que su resolución por un sistema de IA no garantizaría el haber alcanzado una forma de inteligencia general, pero sí el haber logrado un avance hacia esta (Chollet, Knoop, Kamradt, Landers & Pinkard, 2025).

1.1.3. Problema Seleccionado

La problemática central que aborda esta investigación es la dificultad actual que presentan los modelos de IA para demostrar razonamiento y generalizar efectivamente a partir de pocos ejemplos. Particularmente, en *benchmarks* como ARC-AGI se evidencia cómo las arquitecturas actuales, principalmente LLMs, poseen limitaciones significativas en términos de eficiencia, además de sufrir dependencia de grandes volúmenes de datos para su entrenamiento y operación.

1.2. Objetivos

En esta sección se presentan el objetivo general y los objetivos específicos del proyecto. El objetivo general se enfoca en la resolución de la problemática seleccionada, mientras que los objetivos específicos están relacionados con los problemas-causa planteados en el árbol de problemas.

1.2.1. Objetivo General

El objetivo general es desarrollar una arquitectura neuro-simbólica que combine la eficiencia de representaciones simbólicas y la flexibilidad de modelos de lenguaje ligeros, alcanzando una alta capacidad de abstracción y generalización con recursos computacionales moderados en el *benchmark* ARC-AGI.

1.2.2. Objetivos Específicos

O1. Diseñar una arquitectura híbrida que integre modelos de lenguaje ligeros y módulos de razonamiento simbólico para abordar el *benchmark* ARC-AGI considerando las técnicas existentes en el estado del arte.

O2. Implementar una biblioteca de transformaciones genéricas y reutilizables para la resolución de los distintos tipos de problemas propuestos en ARC-AGI, de forma que estas se integren como módulo de razonamiento simbólico en la arquitectura.

O3. Entrenar la arquitectura asegurando un costo computacional bajo mediante técnicas de *fine-tuning* y *test-time training* de manera que la solución sea eficiente en términos de uso de recursos y tiempo de inferencia.

O4. Evaluar la arquitectura propuesta en el *benchmark* ARC-AGI y compararla con el estado del arte, compartiendo los resultados en un repositorio público.

1.2.3. Resultados Esperados

Los resultados esperados se detallarán de acuerdo a los objetivos específicos planteados en la sección anterior.

O1. Diseñar una arquitectura híbrida que integre modelos de lenguaje ligeros y módulos de razonamiento simbólico para abordar el *benchmark* ARC-AGI considerando las técnicas existentes en el estado del arte.

- **R1.** Selección de técnicas y algoritmos usados en el estado del arte que se alineen con el enfoque neuro-simbólico.
- **R2.** Selección de datasets incluyendo el original de ARC-AGI, de forma que permitan el entrenamiento y evaluación de la arquitectura.
- **R3.** *Pipeline* base donde se integren los módulos simbólicos y los modelos de lenguaje seleccionados.

O2. Implementar una biblioteca de transformaciones genéricas y reutilizables para la resolución de los distintos tipos de problemas propuestos en ARC-AGI, de forma que estas se integren como módulo de razonamiento simbólico en la arquitectura.

- **R1.** Biblioteca escrita en Python que integre un conjunto de transformaciones elementales como rotación, reflexión, coloreo, agrupamiento y otras operaciones que permitan la resolución de los problemas atómicos propuestos en ARC-AGI.
- **R2.** Validación de la biblioteca mediante su evaluación en subtarefas de ARC-AGI.
- **R3.** Documentación que detalle el uso de la biblioteca, las funciones que incluye, y ejemplos de uso.

O3. Entrenar la arquitectura asegurando un costo computacional bajo mediante técnicas de *fine-tuning* y *test-time training* de manera que la solución sea eficiente en términos de uso de recursos y tiempo de inferencia.

- **R1.** Aplicación de *fine-tuning* con los datasets previamente seleccionados y que sirva para ajuste de capas y parámetros clave, optimizando así la abstracción requerida.
- **R2.** Evaluación cuantitativa de los recursos usados como consumo de GPU/CPU, memoria y tiempos de inferencia.

O4. Evaluar la arquitectura propuesta en el *benchmark* ARC-AGI y compararla con el estado del arte, compartiendo los resultados en un repositorio público.

- **R1.** Evaluación de la arquitectura en el dataset público dado que es la principal fuente de evaluación del *benchmark*.
- **R2.** Comparación de resultados obtenidos con los de otras arquitecturas existentes en el estado del arte, como los ganadores de la competencia en Kaggle del 2024.
- **R3.** Discusión final sobre las limitaciones encontradas y las oportunidades de mejora en la propuesta.
- **R4.** Publicación del código en un repositorio abierto incluyendo la biblioteca desarrollada, los reportes de la arquitectura implementada y resultados obtenidos.

1.2.4. Mapeo de Resultados Esperados y Medios de Verificación

Esta sección detalla cómo cada resultado esperado se asocia a un medio de verificación específico, y a indicadores objetivamente verificables (IOV). Este mapeo permite establecer una relación clara entre los objetivos planteados y los métodos empleados para evaluar su cumplimiento, permitiendo medir el progreso y el éxito del proyecto.

O1. Diseñar una arquitectura híbrida que integre modelos de lenguaje ligeros y módulos de razonamiento simbólico para abordar el <i>benchmark</i> ARC-AGI considerando las técnicas existentes en el estado del arte.		
Resultado Esperado	Medio de Verificación	IOV
R1. Selección de técnicas y algoritmos usados en el estado del arte que se alineen con el enfoque neuro-simbólico.	- Capítulo en la tesis que reporte técnicas utilizadas en arquitecturas neuro-simbólicas.	- Reporte de al menos 4 técnicas usadas en arquitecturas neuro-simbólicas con justificación de su selección. Este debe ser aprobado por un experto en IA.
R2. Selección de datasets incluyendo el original de ARC-AGI, de forma que permitan el entrenamiento y evaluación de la arquitectura.	- Repositorio organizado en Google Drive con los datasets seleccionados.	- Reporte de al menos 3 datasets adicionales a ARC-AGI junto con la justificación de su selección y análisis de sus características.
R3. <i>Pipeline</i> base donde se integren los módulos simbólicos y los modelos de lenguaje seleccionados.	- Código fuente en Python del pipeline base implementado y funcionando para los datasets elegidos.	- Repositorio en línea accesible. - Informe técnico que detalle la arquitectura propuesta. Este debe ser aprobado por un experto en IA.

Tabla 1: Resultados esperados, medios de verificación e IOV para el O1

O2. Implementar una biblioteca de transformaciones genéricas y reutilizables para la resolución de los distintos tipos de problemas propuestos en ARC-AGI, de forma que estas se integren como módulo de razonamiento simbólico en la arquitectura.		
Resultado Esperado	Medio de Verificación	IOV
R1. Biblioteca escrita en Python que integre un conjunto de transformaciones elementales que permitan la resolución de los problemas atómicos propuestos en ARC-AGI.	- Código fuente en Python de la biblioteca con las funciones organizadas.	- Repositorio en línea con código fuente accesible donde se implementen al menos 10 operaciones atómicas.
R2. Validación de la biblioteca mediante su evaluación en subtarear preseleccionadas de ARC-AGI.	- Notebook para evaluación sobre un subconjunto de subtarear de los datasets elegidos.	- Precisión superior al 80 % por parte de las funciones de la biblioteca para la resolución de tarear atómicas de los datasets elegidos.
R3. Documentación que detalle el uso de la biblioteca y las funciones que incluye.	- Notebooks que demuestren el uso de la biblioteca con ejemplos.	- Notebooks publicados en el repositorio del proyecto que demuestren el uso de todas las funciones implementadas.

Tabla 2: Resultados esperados, medios de verificación e IOV para el O2

O3. Entrenar la arquitectura asegurando un costo computacional bajo mediante técnicas de <i>fine-tuning</i> y <i>test-time training</i> de manera que la solución sea eficiente en términos de uso de recursos y tiempo de inferencia.		
Resultado Esperado	Medio de Verificación	IOV
R1. Aplicación de <i>fine-tuning</i> con los datasets previamente seleccionados y que sirva para ajuste de capas y parámetros clave, optimizando así la abstracción requerida por cada tarea.	- Registro de hiperparámetros y pesos finales del modelo ajustado.	- Reporte de al menos 2 métricas comparativas entre el modelo base y el modelo ajustado, así como la información de los hiperparámetros actualizados. Este debe ser aprobado por un experto en IA.
R2. Evaluación cuantitativa de los recursos usados como consumo de GPU/CPU, memoria y tiempos de inferencia.	- Análisis comparativo entre los recursos usados por el modelo base y el modelo ajustado. - Detalle de la relación costo/beneficio de la arquitectura propuesta en las fases de entrenamiento y evaluación.	- Reporte de al menos 3 métricas comparativas entre el modelo base y el modelo ajustado. - Detalle del proceso de evaluación y los resultados obtenidos, que demuestre la mejora en rendimiento del modelo. Este debe ser aprobado por un experto en IA.

Tabla 3: Resultados esperados, medios de verificación e IOV para el O3

O4. Evaluar la arquitectura propuesta en el <i>benchmark</i> ARC-AGI y compararla con el estado del arte, compartiendo los resultados en un repositorio público.		
Resultado Esperado	Medio de Verificación	IOV
R1. Evaluación de la arquitectura en el dataset público dado que es la principal fuente de evaluación del <i>benchmark</i> .	- Código en Python que sirva para la evaluación del modelo final en los datasets oficiales de ARC-AGI. - Reporte de resultados con las métricas obtenidas.	- Repositorio en línea con código accesible donde se evidencie la evaluación del modelo en ambos datasets. - Reporte de resultados en el repositorio del proyecto que incluya las métricas obtenidas y su justificación. Este debe ser aprobado por un experto en IA.
R2. Comparación de resultados obtenidos con los de otras arquitecturas existentes en el estado del arte.	- Reporte con análisis comparativo entre los resultados obtenidos y los resultados del estado del arte.	- Reporte con análisis estadístico entre la solución propuesta y el estado del arte, incluyendo tablas y gráficos comparativos. Este debe ser aprobado por un experto en IA.
R3. Discusión final sobre las limitaciones encontradas y las oportunidades de mejora en la propuesta.	- Reporte de conclusiones donde se discuta la efectividad de las técnicas utilizadas.	- Reporte de al menos 3 limitaciones identificadas y 2 oportunidades de mejora.
R4. Publicación del código en un repositorio abierto incluyendo la biblioteca desarrollada, los reportes de la arquitectura implementada y resultados obtenidos.	- Repositorio público en GitHub con licencia MIT que incluya el código fuente, reportes e informes generados durante el proyecto.	- Repositorio público en GitHub con licencia MIT subido tras la finalización del proyecto. - Documento README que resuma el repositorio y presente a grandes rasgos la investigación realizada.

Tabla 4: Resultados esperados, medios de verificación e IOV para el O4